

β -VAE con Cyclical Annealing

Aprendizaje de representaciones estructuradas en datos 2D/3D

Marcos Francés Requena^{*}

Luna Camacho Boluda^{**}

Irene Fátima Robles Cano^{***}

Ángel Adrián Bustios Cancino^{****}

Tutor Proyecto: Nahuel Emiliano García D'Urso^{*****}

Grado en Ingeniería en Inteligencia Artificial

Escuela Politécnica Superior, Universidad de Alicante

Redes Neuronales y Aprendizaje Profundo — Curso 2025/2026

Resumen

*Este trabajo estudia el aprendizaje de representaciones estructuradas mediante Autocodificadores Variacionales con annealing cíclico del hiperparámetro β (β -VAE cíclico), un esquema que evita el posterior collapse típico de los VAE estándar y compatibiliza fidelidad de reconstrucción con regularización del espacio latente. El proyecto se organiza en dos fases. En la **Parte 1** se evalúa el β -VAE cíclico sobre los siguientes datasets MNIST-2D, MNIST-3D voxelizado, CelebA y Food-101— comparándolo con un VAE estándar como baseline: se observan clusters latentes más compactos en MNIST y los límites de la arquitectura convolucional al escalar a imágenes naturales de alta resolución. En la **Parte 2** se aborda la clasificación 3D sobre ModelNet (3/10/25/40 clases) acoplando el β -VAE cíclico a una codificación Basis Point Sets (BPS), que transforma cada nube de puntos en un vector denso de dimensión fija $3K$, y a una cabeza clasificadora entrenada conjuntamente con términos de reconstrucción, KL, distancia de Chamfer y entropía cruzada. El sistema alcanza un **95.45 % en ModelNet10**, superando a todos los métodos del benchmark público de referencia incluido PolyNet, y un **82.54 % en ModelNet40**.*

^{*}mfr73@alu.ua.es

^{**}lcb52@alu.ua.es

^{***}ifrc1@alu.ua.es

^{****}aabc2@alu.ua.es

^{*****}nahuel.garcia@ua.es

Índice

1. Introducción	3
2. Trabajo Relacionado	3
3. Descripción del Problema y los Datos	4
3.1. Parte 1. β -VAE en datos 2D/3D	4
3.1.1. Definición formal de la tarea	4
3.1.2. Dataset	4
3.2. Parte 2. Ciclycal β -VAE + BPS en ModelNet	5
3.2.1. Definición formal de la tarea	5
3.2.2. Dataset	6
4. Metodología	7
4.1. Parte 1. β -VAE en datos 2D/3D	7
4.1.1. Preprocesamiento	7
4.1.2. Modelos: VAE <i>baseline</i> y β -VAE con <i>cyclical annealing</i>	7
4.1.3. Protocolo de evaluación	7
4.2. Parte 2. Ciclycal β -VAE + BPS en ModelNet	8
4.2.1. Preprocesamiento	8
4.2.2. Comparativa con modelos de Aprendizaje Automático	8
4.2.3. Capacidad de representación frente a escalabilidad de clases	9
4.2.4. Protocolo de evaluación	9
5. Experimentos y Resultados	10
5.1. Parte 1. β -VAE en datos 2D/3D	10
5.1.1. Configuración experimental	10
5.1.2. Dinámica del entrenamiento: <i>cyclical annealing</i>	10
5.1.3. Calidad de reconstrucción visual	11
5.1.4. Estructura del espacio latente: proyecciones t-SNE	12
5.1.5. Interpolaciones en el espacio latente	14
5.1.6. Comparativa VAE vs. β -VAE y limitaciones	14
5.2. Parte 2. Ciclycal β -VAE + BPS en ModelNet	14
5.2.1. Configuración experimental	14
5.2.2. Resultados comparativos	15
5.2.3. Efecto de la resolución BPS	15
5.2.4. Comparativa aprendizaje profundo vs. aprendizaje automático clásico	16
5.2.5. Estructura del espacio latente	17
5.2.6. Calidad de reconstrucción e interpolación en el espacio latente	18
5.2.7. Comparación con el estado del arte en ModelNet10 y ModelNet40	19
6. Conclusiones	20
A. Contribución individual	23
B. Enlace al repositorio	23
C. Enlace Kaggle	23

1. Introducción

El proyecto aborda el desafío del aprendizaje de representaciones estructuradas en datos visuales de alta dimensionalidad mediante el uso de modelos generativos probabilísticos. En particular, la investigación se centra en la familia de los Autocodificadores Variacionales (β -VAE) y su capacidad para inferir espacios latentes continuos y expresivos que capturen la variabilidad geométrica y semántica subyacente de las observaciones. Dado que la optimización de estos modelos presenta frecuentemente obstáculos como el colapso posterior o la tensión estructural entre la fidelidad de la reconstrucción y la regularización impuesta por la divergencia KL, la metodología adoptada hace uso de esquemas de *cyclical annealing* para estabilizar el entrenamiento y favorecer una organización progresiva del espacio latente.

Para evaluar de forma sistemática este enfoque, el proyecto se estructura en dos fases: en la **Parte 1**, se analiza la capacidad generativa y la topología del espacio latente del β -VAE cíclico sobre dominios heterogéneos, abarcando desde imágenes bidimensionales (MNIST-2D, CelebA, Food-101) hasta representaciones volumétricas discretas (MNIST-3D). Posteriormente, en la **Parte 2**, se traslada al análisis y clasificación de modelos tridimensionales utilizando los conjuntos de datos de ModelNet. Con el fin de evitar irregularidades y el alto coste computacional de las nubes de puntos 3D, se integra la codificación geométrica mediante *Basis Point Sets* (BPS). A través de este diseño, se explora la escalabilidad y los límites de la representación aprendida frente a métodos de aprendizaje automático clásico al aumentar el número de categorías.

2. Trabajo Relacionado

El punto de partida teórico lo constituyen los Autocodificadores Variacionales (VAE), formalizados por Kingma y Welling [4] y en español por De la Torre [1]. A diferencia de los autoencoders deterministas, los VAE parametrizan una distribución sobre el espacio latente, lo que les confiere capacidad generativa. Su entrenamiento maximiza la cota inferior variacional (ELBO), que descompone la pérdida en un término de reconstrucción y una regularización KL respecto a una prior gaussiana, optimizable mediante el truco de reparametrización $\mathbf{z} = \boldsymbol{\mu}_\phi(\mathbf{x}) + \boldsymbol{\sigma}_\phi(\mathbf{x}) \odot \boldsymbol{\varepsilon}$, compatible con SGD.

Higgins et al. [3] extienden este marco con el β -VAE, que pondera el término KL por un hiperparámetro $\beta \geq 1$. Su derivación lagrangiana bajo condiciones KKT muestra que β controla la capacidad del canal latente: valores $\beta > 1$ fuerzan al modelo a comprimir más eficientemente y favorecen el *disentanglement* de factores generativos independientes, propiedad validada empíricamente sobre CelebA y caras sintéticas. El propio trabajo reconoce un compromiso estructural reconstrucción: β demasiado alto produce reconstrucciones borrosas al imponer un cuello de botella demasiado estrecho.

Este compromiso motiva el *cyclical annealing schedule* de Fu et al. [6], que ataca el *KL vanishing* o colapso posterior repitiendo cíclicamente el calentamiento de β desde 0 hasta $\beta_{\text{máx}}$ a lo largo del entrenamiento. Al reiniciar $\beta = 0$ al comienzo de cada ciclo, el camino latente se reabre y el decoder se entrena con códigos progresivamente mejores. Los autores validan el esquema en tareas de PLN (Penn Treebank, diálogo, Yelp), donde el calendario cíclico supera al monótono sin coste adicional. En este proyecto se adopta $M = 4$ ciclos sobre $T = 100$ épocas.

En el eje de representación 3D, Prokudin et al. [2] proponen los *Basis Point Sets* (BPS) para superar las limitaciones de las dos familias dominantes hasta 2019: las representaciones volumétricas escalan cúbicamente con celdas mayoritariamente vacías, mientras que arquitecturas como PointNet requieren cientos de millones de FLOPs. BPS codifica cada nube como los vectores delta entre K puntos de base fijos (muestreados de una bola unitaria) y su vecino más cercano en la nube, produciendo un vector de dimensión fija $\mathbb{R}^{K \times 3}$ apto para cualquier MLP o SVM.

El benchmark de referencia lo establecen Wu et al. [5] con **ModelNet** y sus particiones estándar **ModelNet10** y **ModelNet40**, empleadas en la Parte 2. Achlioptas et al. [7] complementan la perspectiva generativa proponiendo un autoencoder entrenado con métricas permutation-invariant (*Earth Mover’s Distance* y *Chamfer Distance*) que demuestra que un espacio latente no supervisado sobre ModelNet es suficiente para clasificación, interpolación y analogías; la diferencia con el presente trabajo es que aquí la invarianza a permutaciones se resuelve antes del modelo mediante BPS.

3. Descripción del Problema y los Datos

3.1. Parte 1. β -VAE en datos 2D/3D

3.1.1. Definición formal de la tarea

La primera parte aborda una tarea de **aprendizaje generativo no supervisado** mediante modelos de variable latente continua. Dado $\mathcal{D} = \{\mathbf{x}^{(i)}\}_{i=1}^N$ muestreado de una distribución desconocida $p_{\text{data}}(\mathbf{x})$, se busca aprender $p_{\theta}(\mathbf{x}) = \int p_{\theta}(\mathbf{x} | \mathbf{z}) p(\mathbf{z}) d\mathbf{z}$ con prior $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ y $\mathbf{z} \in \mathbb{R}^{d_z}$. El espacio de entrada adopta dos modalidades: **imágenes 2D** (MNIST-2D, CelebA, Food-101) con $\mathbf{x} \in \mathbb{R}^{C \times H \times W}$ ($C \in \{1, 3\}$, $H = W \in \{32, 224\}$) normalizadas a $[-1, 1]$, y **volúmenes vóxel 3D** (MNIST-3D) con $\mathbf{x} \in \{-1, +1\}^{1 \times 32^3}$.

El codificador $q_{\phi}(\mathbf{z} | \mathbf{x}) = \mathcal{N}(\mathbf{z}; \boldsymbol{\mu}_{\phi}(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_{\phi}^2(\mathbf{x})))$ parametriza una gaussiana diagonal sobre el espacio latente, con $d_z \in \{2, 4, 8, 16, 32, 48, 64, 128\}$ según el experimento. El decodificador $p_{\theta}(\mathbf{x} | \mathbf{z})$, simétrico y basado en convoluciones transpuestas (2D o 3D), reconstruye la entrada a partir de $\mathbf{z} = \boldsymbol{\mu}_{\phi}(\mathbf{x}) + \boldsymbol{\sigma}_{\phi}(\mathbf{x}) \odot \boldsymbol{\varepsilon}$, con $\boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.

Dado que $\log p_{\theta}(\mathbf{x})$ es intratable, se maximiza su cota inferior variacional. En el marco del β -VAE [3] la pérdida es:

$$\mathcal{L}_{\beta\text{-VAE}}(\theta, \phi; \mathbf{x}) = \underbrace{\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2}_{\mathcal{L}_{\text{rec}}} + \beta \underbrace{D_{\text{KL}}(q_{\phi}(\mathbf{z} | \mathbf{x}) \| \mathcal{N}(\mathbf{0}, \mathbf{I}))}_{\mathcal{L}_{\text{KL}}}, \quad (1)$$

donde $\beta = 1$ corresponde al VAE estándar [4], usado como *baseline* en MNIST-2D y MNIST-3D. Para el β -VAE, el hiperparámetro se programa cíclicamente [6]: con E épocas y C ciclos de período $T_c = E/C$, β aumenta linealmente desde 0 hasta $\beta_{\text{máx}}$ durante la primera mitad de cada ciclo y se mantiene constante en la segunda,

$$\beta^{(e)} = \beta_{\text{máx}} \cdot \min\left(1, \frac{(e-1) \bmod T_c}{T_c/2}\right). \quad (2)$$

El entrenamiento usa Adam ($\alpha = 10^{-3}$, $B = 128$) con *early stopping* ($p = 20$ épocas) sobre la reconstrucción en validación, restaurando los pesos del mejor modelo. Las etiquetas de clase no se utilizan en el entrenamiento; se reservan únicamente para la evaluación cualitativa mediante t-SNE. En Food-101, la mayor resolución (3×224^2 , $d = 150528$) provocó valores NaN a partir de la época 5; para mitigarlo se normaliza la reconstrucción por el batch, se recortan los parámetros latentes ($\log \sigma_j^2 \in [-15, 5]$, $\mu_j \in [-15, 15]$) y se aplica `clip_grad_norm_ = 0.5`.

3.1.2. Dataset

La Parte 1 emplea cuatro *datasets* de naturaleza heterogénea para evaluar la capacidad de generalización del cíclico β -VAE a distintas modalidades de datos visuales: dígitos en 2D (**MNIST-2D**), dígitos representados como nubes de puntos 3D convertidas a vóxeles (**MNIST-3D**), rostros de celebridades (**CelebA**) e imágenes de alimentos (**Food-101**). En todos los casos la tarea es no supervisada.

La Tabla 1 resume las características principales de los *datasets* utilizados en esta fase.

Tabla 1: Características de los *datasets* empleados en la Fase 1.

Característica	Valor
<i>MNIST-2D</i>	
Fuente / enlace	huggingface.co/datasets/ylecun/mnist
Nº de instancias	60 000 train + 10 000 test
Nº de <i>features</i>	$1 \times 32 \times 32 = 1024$ (escala de grises, reescalado a 32×32)
Variable objetivo (no usada en train)	Dígito manuscrito (10 clases: 0–9)
Distribución de clases	Aproximadamente uniforme ($\approx 10\%$ por clase)
Valores ausentes	No
Licencia	CC BY-SA 3.0
<i>MNIST-3D</i>	
Fuente / enlace	github.com/thunguyenphuoc/3DMNIST
Nº de instancias	5 000 train + 1 000 valid + 1 000 test
Nº de <i>features</i>	$1 \times 32^3 = 32768$ (vóxel binario normalizado a $[-1, 1]$)
Variable objetivo (no usada en train)	Dígito manuscrito (10 clases: 0–9)
Distribución de clases	Aproximadamente uniforme ($\approx 10\%$ por clase)
Valores ausentes	No
Licencia	No especificada (repositorio público)
<i>CelebA</i>	
Fuente / enlace	mmlab.ie.cuhk.edu.hk/projects/CelebA.html
Nº de instancias	162 770 train + 19 962 test
Nº de <i>features</i>	$1 \times 32 \times 32 = 1024$ (CenterCrop 178, Resize 32, escala de grises)
Variable objetivo (no usada en train)	Atributos faciales binarios (40 atributos; no empleados)
Distribución de clases	Continua / multilabel; no aplicable
Valores ausentes	No
Licencia	Uso académico no comercial
<i>Food-101 (subconjunto)</i>	
Fuente / enlace	data.vision.ee.ethz.ch/cvl/datasets_extra/food-101
Nº de instancias (efectivas)	3 000 train + 1 000 test (4 clases de las 101 originales)
Nº de <i>features</i>	$3 \times 224 \times 224 = 150528$ (RGB, Resize 224×224 , norm. $[-1, 1]$)
Variable objetivo (no usada en train)	Categoría culinaria; subconjunto: clases 0–3
Distribución de clases	Uniforme (750 train + 250 test por clase)
Valores ausentes	No
Licencia	Uso académico

3.2. Parte 2. Ciclycal β -VAE + BPS en ModelNet

3.2.1. Definición formal de la tarea

La segunda parte aborda **clasificación de nubes de puntos 3D**. Dado un modelo 3D representado como nube $\mathcal{P} = \{\mathbf{p}_i\}_{i=1}^N \subset \mathbb{R}^3$, se busca $f: \mathcal{X} \rightarrow \mathcal{Y}$ con $\mathcal{Y} = \{0, 1, \dots, C-1\}$ y $C \in \{3, 10, 25, 40\}$ según el subconjunto de ModelNet.

La tarea no se aborda directamente sobre la nube bruta, sino mediante una representación intermedia obtenida con *Basis Point Sets* (BPS). Dado un conjunto fijo de K puntos de base $\mathcal{B} = \{\mathbf{b}_k\}_{k=1}^K$ generados en una esfera de radio r , la codificación BPS de la nube normalizada $\hat{\mathcal{P}}$ es

$$\phi(\hat{\mathcal{P}}) = [\mathbf{p}_1^* - \mathbf{b}_1, \dots, \mathbf{p}_K^* - \mathbf{b}_K] \in \mathbb{R}^{K \times 3}, \quad (3)$$

con $\mathbf{p}_k^* = \arg \min_{\mathbf{p} \in \hat{\mathcal{P}}} \|\mathbf{p} - \mathbf{b}_k\|_2$. La versión aplanada $\mathbf{x} = \text{vec}(\phi(\hat{\mathcal{P}})) \in \mathbb{R}^{3K}$ alimenta al modelo, con $K \in \{256, 512, 1024\}$.

El núcleo del sistema es un β -VAE **cíclico** con encoder $q_\phi(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}_\phi(\mathbf{x}), \text{diag}(\boldsymbol{\sigma}_\phi^2(\mathbf{x})))$ y $d_z = 64$, complementado con una cabeza clasificadora $p_\psi(y \mid \mathbf{x})$. La pérdida total combina cuatro términos:

$$\mathcal{L}(\theta, \phi, \psi; \mathbf{x}, y, \beta) = \underbrace{\|\mathbf{x} - \hat{\mathbf{x}}\|_2^2}_{\text{rec. BPS}} + \beta \underbrace{D_{\text{KL}}(q_\phi \| p)}_{\text{KL}} + \lambda_{\text{Ch}} \underbrace{d_{\text{Ch}}(\hat{\mathcal{P}}, \mathcal{P})}_{\text{Chamfer}} + \lambda_{\text{CE}} \underbrace{\mathcal{L}_{\text{CE}}(\hat{y}, y)}_{\text{clasif.}}, \quad (4)$$

donde $d_{\text{Ch}}(\mathcal{A}, \mathcal{B}) = \frac{1}{2}(\frac{1}{|\mathcal{A}|} \sum_{\mathbf{a}} \min_{\mathbf{b}} \|\mathbf{a} - \mathbf{b}\|_2^2 + \frac{1}{|\mathcal{B}|} \sum_{\mathbf{b}} \min_{\mathbf{a}} \|\mathbf{b} - \mathbf{a}\|_2^2)$ es la distancia de Chamfer simétrica calculada entre la nube original y la reconstruida desde los BPS decodificados, $\mathcal{L}_{\text{CE}}$ la entropía cruzada categórica, y $\lambda_{\text{Ch}} = 0,5$, $\lambda_{\text{CE}} = 1,0$ los pesos base. El término Chamfer aporta supervisión geométrica en el espacio de la nube de puntos, complementando al MSE en el espacio BPS.

El hiperparámetro β se actualiza cíclicamente con $N_{\text{cycles}} = 4$ sobre $T = 100$ épocas mediante una rampa cosenoidal,

$$\beta(t) = \beta_{\text{máx}} \cdot \frac{1 - \cos\left(\pi \frac{t \bmod T_c}{T_c - 1}\right)}{2}, \quad T_c = \frac{T}{N_{\text{cycles}}}, \quad (5)$$

con $\beta_{\text{máx}} = 1$. La métrica principal es la exactitud de clasificación en test, complementada con la distancia de Chamfer media como indicador de calidad geométrica.

3.2.2. Dataset

El dataset principal empleado en la segunda fase del proyecto es **ModelNet**. Cabe resaltar que los modelos se distribuyen en formato OFF (*Object File Format*), que codifica la malla poligonal de cada objeto mediante listas de vértices y caras.

Se han considerado cuatro subconjuntos de ModelNet de complejidad creciente: **ModelNet3** (3 clases), **ModelNet10** (10 clases), **ModelNet25** (25 clases) y **ModelNet40** (40 clases). Cada subconjunto mantiene la partición estándar *train/test* provista por los autores. Para cada modelo se muestrean $N = 1000$ puntos aleatorios sobre los vértices de la malla, que se normalizan a la esfera unitaria antes de calcular la codificación BPS.

La Tabla 2 resume las características principales del *dataset* utilizado:

Tabla 2: Características del <i>dataset</i> .	
Característica	Valor
Fuente / enlace	ModelNet [5]; Kaggle Link
Nº de instancias (ModelNet40)	12311 (9843 train + 2468 test)
Nº de <i>features</i> (BPS-256)	$256 \times 3 = 768$ por muestra
Nº de <i>features</i> (BPS-512)	$512 \times 3 = 1536$ por muestra
Nº de <i>features</i> (BPS-1024)	$1024 \times 3 = 3072$ por muestra
Variable objetivo	Categoría semántica del objeto (p.ej. <i>chair</i> , <i>table</i>)
Distribución de clases	Desequilibrio moderado; clases más frecuentes: <i>chair</i> y <i>desk</i>
Preprocesamiento	Muestreo de 1000 puntos, normalización a esfera unitaria, codificación BPS
Valores ausentes	estandarizada (media y desv. típica de train aplicadas a test)
Licencia	No, mallas corruptas o con < 10 vértices son descartadas
	Uso académico y de investigación

4. Metodología

4.1. Parte 1. β -VAE en datos 2D/3D

4.1.1. Preprocesamiento

El preprocesamiento adapta cada *dataset* al formato requerido por las arquitecturas convolucionales: valores normalizados al intervalo $[-1, 1]$ y resolución uniforme dentro de cada experimento. En **MNIST-2D** las imágenes se reescalan a 32×32 y se normalizan con $(x - 0,5)/0,5$. En **MNIST-3D**, las nubes HDF5 se voxelizan a 32^3 con normalización min-max por coordenada, activando con 1,0 las celdas ocupadas y normalizando el volumen a $[-1, 1]$. En **CelebA** se aplica `CenterCrop(178)`, `Resize(32)`, `Grayscale(1)` y la misma normalización; la partición train/test se obtiene con `train_test_split 80/20 (random_state=42)`. En **Food-101** se reescala a 224×224 con normalización por canal y se restringe a las cuatro primeras clases (3000 train + 1000 test). Ningún dataset presenta valores ausentes estructurales. La Tabla 3 resume las transformaciones aplicadas.

Tabla 3: Cadena de preprocesamiento por *dataset* en la Fase 1.

Dataset	Transformaciones	Resolución final	Canales
MNIST-2D	<code>Resize(32)</code> , <code>Normalize(0.5, 0.5)</code>	32×32	1
MNIST-3D	Voxelización min-max 32^3 , $(v-0,5)/0,5$	$32 \times 32 \times 32$	1
CelebA	<code>CenterCrop(178)</code> , <code>Resize(32)</code> , <code>Grayscale(1)</code> , <code>Normalize(0.5, 0.5)</code>	32×32	1
Food-101	<code>Resize(224)</code> , <code>Normalize((0.5)×3, (0.5)×3)</code>	224×224	3 (RGB)

4.1.2. Modelos: VAE *baseline* y β -VAE con *cyclical annealing*

Como modelo de referencia se entrena un **VAE estándar** [4] ($\beta = 1$ sin annealing) sobre MNIST-2D, MNIST-3D y CelebA. La elección es natural por tres razones: (1) es el modelo fundacional del que deriva el β -VAE, por lo que cualquier diferencia es atribuible al *cyclical annealing*; (2) comparte arquitectura encoder-decoder, garantizando comparativa justa en capacidad paramétrica; (3) es la referencia habitual de la literatura.

El modelo principal es el **β -VAE con *cyclical annealing*** [6], aplicado sobre MNIST-2D, MNIST-3D y Food-101. Su elección está motivada por dos limitaciones del VAE estándar: la presión uniforme de la KL puede provocar *posterior collapse*, y un $\beta > 1$ fijo mejora el *disentanglement* pero degrada la reconstrucción. El annealing cíclico ($E = 100$, $C = 4$, $T_c = 25$) resuelve la tensión haciendo oscilar β entre 0 y $\beta_{\text{máx}} = 1$: al inicio de cada ciclo el modelo aprende a reconstruir sin restricción, y en la segunda mitad la regularización progresiva organiza el espacio latente. La función de pérdida es la presentada en la Sección 3 con la KL ponderada por $\beta^{(e)}$; para los datos 3D la reconstrucción se normaliza por batch por estabilidad numérica.

La arquitectura encoder-decoder es convolucional y simétrica. Para datos 2D, el encoder consta de tres bloques `Conv2d` con kernel 4×4 , stride 2 y padding 1, con `BatchNorm2d` y `LeakyReLU(0.2)` entre capas, seguidos de dos capas lineales que producen μ_ϕ y $\log \sigma_\phi^2 \in \mathbb{R}^{d_z}$ a partir del mapa aplanado de $128 \times 4 \times 4 = 2048$. El decoder es simétrico con tres bloques `ConvTranspose2d` y activación `Tanh` de salida. Para MNIST-3D, la estructura se extiende a `Conv3d/ConvTranspose3d` (mapa aplanado $128 \times 4^3 = 8192$). Se barren dimensiones latentes $d_z \in \{2, 4, 8, 16, 32, 48, 64\}$ para MNIST-2D, $d_z \in \{2, 4, 8, 16, 32, 48, 64, 128\}$ para MNIST-3D y Food-101, y $d_z \in \{2, 4, 8, 16, 32, 64, 128\}$ para CelebA.

4.1.3. Protocolo de evaluación

Al tratarse de aprendizaje no supervisado, no hay métrica de clasificación directa. El protocolo combina la métrica cuantitativa de **error de reconstrucción** (MSE) en test, junto con la

evolución época a época de la KL y β para verificar el funcionamiento del annealing. La evaluación cualitativa comprende tres análisis: (1) **visualización de 16 pares** original/reconstrucción de muestras fijas de test, mostrando para 3D el corte central del volumen; (2) **proyecciones t-SNE** a 2D (`random_state=42`) sobre las medias μ_ϕ del test, coloreadas por clase en MNIST y sin etiquetas en CelebA; (3) **interpolaciones lineales** $z(\alpha) = (1 - \alpha)z_1 + \alpha z_2$ con $n_{\text{interp}} = 10$ (2D, CelebA) o 15 (3D, sobre las medias μ_ϕ para eliminar variabilidad estocástica). La comparación VAE vs. β -VAE se realiza sobre los mismos conjuntos e idéntica arquitectura, variando solo la pérdida y el calendario de β .

4.2. Parte 2. Ciclycal β -VAE + BPS en ModelNet

4.2.1. Preprocesamiento

El *pipeline* de preprocesamiento transforma cada modelo 3D bruto en un vector de características estable mediante cuatro etapas. (1) **Carga y validación**: los modelos OFF se filtran descartando mallas con $V < 10$ vértices o coordenadas no finitas. (2) **Muestreo**: se extraen $N = 1000$ vértices aleatorios (con reposición si $V < N$), con semilla derivada de la ruta del archivo para reproducibilidad. (3) **Normalización**: la nube $\mathcal{P} \in \mathbb{R}^{N \times 3}$ se centra en su centroide y se escala por el radio máximo,

$$\hat{\mathbf{p}}_i = \frac{\mathbf{p}_i - \bar{\mathbf{p}}}{\max_j \|\mathbf{p}_j - \bar{\mathbf{p}}\|_2 + \varepsilon}, \quad \varepsilon = 10^{-8}, \quad (6)$$

dejando la nube inscrita en la bola unitaria; centroide y escala se conservan para desnormalización posterior. (4) **Codificación BPS**: con un conjunto fijo de K puntos de base muestreados aleatoriamente en una esfera de radio $r = 1,1$ (semilla global $s = 42$), se calcula el tensor de vectores diferencia $\mathbf{x} \in \mathbb{R}^{K \times 3}$ definido en la Sección 3, con $K \in \{256, 512, 1024\}$. Finalmente, los vectores se estandarizan por característica con los estadísticos del conjunto de entrenamiento $\tilde{\mathbf{x}} = (\mathbf{x} - \hat{\mu}_{\text{tr}})/(\hat{\sigma}_{\text{tr}} + \varepsilon)$, aplicando los mismos parámetros al test para evitar filtración. El pipeline se paraleliza con `ProcessPoolExecutor` y los arrays se guardan en `.npy`. La Tabla 4 resume las configuraciones evaluadas.

Tabla 4: Configuraciones de BPS evaluadas por subconjunto de ModelNet.

Dataset	Clases	K (puntos BPS)	Dim. entrada ($3K$)
ModelNet3	3	256 / 512 / 1024	768 / 1536 / 3072
ModelNet10	10	256 / 512 / 1024	768 / 1536 / 3072
ModelNet25	25	256 / 512 / 1024	768 / 1536 / 3072
ModelNet40	40	256 / 512 / 1024	768 / 1536 / 3072

4.2.2. Comparativa con modelos de Aprendizaje Automático

Como punto de referencia se entrena una **Máquina de Vectores Soporte lineal** (`LinearSVC`) directamente sobre los vectores BPS estandarizados $\tilde{\mathbf{x}} \in \mathbb{R}^{3K}$, sin aprendizaje de representación previo. La codificación BPS transforma la nube de puntos en un vector de dimensión fija y normalizado, lo que hace que un clasificador lineal sea directamente aplicable y computacionalmente eficiente incluso en la configuración de mayor resolución ($3K = 3072$). Este modelo actúa de referencia al operar sobre $\tilde{\mathbf{x}}$ sin reducción de dimensionalidad, cuantifica el límite superior de información discriminativa presente en las propias codificaciones BPS, frente al cual se evalúa la ganancia introducida por el aprendizaje profundo del β -VAE. Se añaden además como comparativos secundarios un k -NN ($k = 5$) y un **XGBoost** (100 árboles, profundidad 5, $\eta = 0,1$), ambos ajustados sobre las medias latentes $\mu_\phi(\tilde{\mathbf{x}})$ del encoder entrenado, con el fin de comparar el rendimiento entre métodos de aprendizaje profundo y aprendizaje automático.

4.2.3. Capacidad de representación frente a escalabilidad de clases

El principal reto de este trabajo es escalar una arquitectura generativa y clasificadora conjunta desde problemas con pocas categorías (ModelNet3) hasta escenarios con alta granularidad semántica (ModelNet40). A medida que el número de clases crece, el espacio latente de dimensión fija $d_z = 64$ debe organizar representaciones geométricamente más variadas, y la presión del término KL puede colapsar la estructura discriminativa. Para afrontar este desafío se aplican tres técnicas complementarias.

En el β -VAE estándar [3], la pérdida total es:

$$\mathcal{L}_{\beta\text{-VAE}} = \mathbb{E}_{q_\phi}[\log p_\theta(\mathbf{x} | \mathbf{z})] - \beta D_{\text{KL}}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z})). \quad (7)$$

Para alinear la geometría del espacio latente con la geometría real de los objetos, la pérdida incorpora un término de **distancia de Chamfer** calculado entre la nube de puntos original y la reconstruida a partir de las codificaciones BPS decodificadas:

$$\mathcal{L} = \underbrace{\|\tilde{\mathbf{x}} - \hat{\mathbf{x}}\|^2}_{\text{MSE BPS}} + \beta(t) D_{\text{KL}} + \lambda_{\text{Ch}} d_{\text{Ch}}(\hat{\mathcal{P}}, \mathcal{P}) + \lambda_{\text{CE}} \mathcal{L}_{\text{CE}}(\hat{y}, y), \quad (8)$$

con $\lambda_{\text{Ch}} \in \{0,5, 1,0\}$ y $\lambda_{\text{CE}} \in \{1,0, 2,0\}$ explorados en la búsqueda de hiperparámetros. El término de Chamfer penaliza directamente la fidelidad geométrica de las reconstrucciones 3D y actúa como una supervisión adicional en el espacio de nube de puntos, complementando la pérdida MSE en el espacio BPS que puede ser insensible a errores localizados.

Además, se realiza una búsqueda (Grid Search) sobre las siguientes dimensiones de variación, manteniendo constantes los hiperparámetros de entrenamiento base:

Tabla 5: Espacio de búsqueda de hiperparámetros y arquitecturas.

Hiperparámetro	Valores explorados
Tasa de aprendizaje (η)	$\{10^{-4}, 5 \times 10^{-5}\}$
Tamaño de batch	$\{32, 64\}$
Regularización L_2 (λ_{WD})	$\{10^{-5}, 10^{-6}\}$
Peso Chamfer (λ_{Ch})	$\{0,5, 1,0\}$
Peso clasificación (λ_{CE})	$\{1,0, 2,0\}$
Inicialización de pesos	{por defecto (Kaiming), Xavier uniforme, Xavier normal}
Arquitectura del modelo	{V1 base, V2 más profunda, V3 más ancha}

Las tres arquitecturas propuestas difieren en la capacidad del *encoder/decoder*: **V1** (base) sigue la cadena $3K \rightarrow 1024 \rightarrow 512 \rightarrow 256 \rightarrow d_z$; **V2** (*deeper*) añade una capa intermedia de 768 neuronas; **V3** (*wider*) amplía las capas existentes a $3K \rightarrow 1536 \rightarrow 1024 \rightarrow 512 \rightarrow d_z$. El criterio de selección del mejor modelo es la máxima exactitud de validación (`val_acc`), con *early stopping* de paciencia $P = 15$ épocas.

4.2.4. Protocolo de evaluación

Se emplea la partición train/test estándar de ModelNet, sin validación cruzada adicional. Esta decisión se toma ya que la partición oficial es la utilizada en los trabajos de referencia de la literatura, lo que permite la comparación directa con el estado del arte y que el coste computacional de ejecutar *k-fold* sobre el Grid Search de hiperparámetros completo (> 100 combinaciones $\times$ múltiples valores de $K \times 4$ subconjuntos de ModelNet) resulta inviable. En su lugar, el conjunto de test se utiliza como conjunto de validación durante la búsqueda de hiperparámetros, y los resultados finales se reportan sobre ese mismo conjunto.

La métrica principal es la **exactitud global**:

$$\text{AccGlobal} = \frac{1}{|\mathcal{D}_{\text{te}}|} \sum_{(\mathbf{x}, y) \in \mathcal{D}_{\text{te}}} [\hat{y}(\mathbf{x}) = y]. \quad (9)$$

Esta elección se toma porque ModelNet presenta un desequilibrio de clases moderado pero no extremo, y la AccGlobal es la métrica estándar en los benchmarks de ModelNet10 y ModelNet40, facilitando la comparación directa.

Para caracterizar el comportamiento por clase se reportan adicionalmente:

- **Informe de clasificación:** precisión, exhaustividad y F_1 -score por clase, que permiten identificar confusiones sistemáticas entre categorías geoméricamente similares (e.g. *table/desk*, *chair/sofa*).
- **Matriz de confusión:** visualización completa de los errores de clasificación, especialmente informativa en ModelNet25 y ModelNet40 donde el número de categorías hace que la AccGlobal pueda enmascarar desequilibrios locales.
- **Distancia de Chamfer media** ($\bar{d}_{\text{Ch}}$): calidad geométrica de las reconstrucciones sobre el conjunto de test, que evalúa la faceta generativa del modelo independientemente de la exactitud de clasificación.

Cada configuración de número de clases se ejecuta con $K \in \{256, 512, 1024\}$ puntos de base y a su vez se realiza una búsqueda exhaustiva de hiperparámetros óptimos. Esto permite comparar las precisiones de cada caso frente al coste computacional de incrementar la resolución de la representación BPS.

5. Experimentos y Resultados

5.1. Parte 1. β -VAE en datos 2D/3D

5.1.1. Configuración experimental

Todos los experimentos se ejecutaron con el entorno software común que es PyTorch con optimizador Adam ($\alpha = 10^{-3}$, $B = 128$) y *early stopping* con paciencia $p = 20$ épocas sobre el error de reconstrucción en validación, restaurando los pesos del mejor modelo observado. Para los modelos 3D se añade regularización L_2 con $\lambda_{WD} = 10^{-3}$.

Se entrenan y evalúan dos familias de modelos: el VAE estándar (*baseline*, $\beta = 1$) sobre MNIST-2D, MNIST-3D y CelebA; y el β -VAE con *cyclical annealing* ($C = 4$ ciclos, $E = 100$ épocas, $\beta_{\text{máx}} = 1$) sobre MNIST-2D, MNIST-3D y Food-101. Para cada familia y dataset se entrena un modelo independiente por cada valor de d_z en el rango experimental descrito en la Sección 4. El análisis del efecto de d_z se realiza de forma cualitativa mediante tres herramientas: la evolución de la pérdida de entrenamiento, las proyecciones t-SNE del espacio latente y las interpolaciones entre pares de muestras. Todos los resultados presentados corresponden a $d_z = 64$, salvo las proyecciones t-SNE donde se emplea $d_z = 16$ para facilitar la separabilidad visual de los clusters.

5.1.2. Dinámica del entrenamiento: *cyclical annealing*

La Figura 1 muestra la evolución época a época de la pérdida de reconstrucción normalizada, la divergencia KL y el parámetro β durante el entrenamiento del β -VAE sobre MNIST-2D con $d_z = 64$, que activa *early stopping* en torno a la época 73 (tres ciclos completos y parte del cuarto). El patrón cíclico es claramente identificable: al inicio de cada ciclo ($e = 1, 26, 51, 76$),

β cae bruscamente a 0, liberando la presión sobre el espacio latente y produciendo una caída abrupta de la KL mientras la reconstrucción mejora rápidamente; en la segunda mitad, β aumenta linealmente hasta $\beta_{\text{máx}} = 1$, la KL crece gradualmente y la reconstrucción se estabiliza. La pérdida real cae de ~ 8300 en la época 1 a valores por debajo de 300 a partir de la época 10. Este comportamiento confirma que el annealing cíclico evita el *posterior collapse*: la alternancia entre fases de reconstrucción libre y de regularización permite aprender ambos objetivos de forma complementaria.




Figura 1: Dinámica del entrenamiento del β -VAE sobre MNIST-2D con $d_z = 64$. Izquierda: evolución normalizada de la reconstrucción (verde), KL (rojo) y β (naranja discontinuo). Derecha: pérdida de reconstrucción real (suma de errores cuadráticos por batch). El *early stopping* se activa en torno a la época 73.

5.1.3. Calidad de reconstrucción visual

La Figura 2 muestra 16 pares original/reconstrucción por *dataset* con $d_z = 64$. En **MNIST-2D** (época 1) las reconstrucciones son prácticamente perfectas desde la primera época. En **MNIST-3D** (época 10, corte central del volumen) la estructura global del dígito es reconocible, aunque los bordes presentan pixelado propio de la representación binaria 3D. En **CelebA** (época 16) se capta la estructura general del rostro (contorno, posición de ojos, boca, cabello) pero con notable pérdida de detalle: las reconstrucciones son borrosas y no permiten identificar al sujeto, limitación atribuible a la resolución reducida (32×32) y a la dificultad de comprimir > 160000 rostros en $d_z = 64$. En **Food-101** (época 54) la reconstrucción es deficiente: solo se preserva la gama cromática global, mientras forma, textura y detalle se pierden. Esto se atribuye a la alta variabilidad intra-clase, a la arquitectura convolucional diseñada para 32×32 que no escala eficientemente a 224×224 .




Figura 2: Reconstrucciones representativas (fila superior: originales; fila inferior: reconstrucciones) con $d_z = 64$. De arriba a abajo: MNIST-2D (época 1), MNIST-3D (corte central del volumen voxel, época 10), CelebA (época 16) y Food-101 (época 54). La calidad de reconstrucción decrece notablemente al aumentar la complejidad del dataset.

5.1.4. Estructura del espacio latente: proyecciones t-SNE

La Figura 3 muestra las proyecciones t-SNE 2D de las medias latentes $\mu_\phi(\mathbf{x})$ sobre el conjunto de test con $d_z = 16$. En **MNIST-2D**, ambos modelos producen diez clusters bien definidos, uno por dígito, demostrando una organización semántica coherente sin supervisión; el β -VAE genera clusters ligeramente más compactos y con menor solapamiento entre dígitos morfológicamente similares (3 vs. 8, 4 vs. 9), evidenciando una regularización más efectiva. En **MNIST-3D** los clusters son considerablemente menos compactos: solo algunos dígitos (p.ej. el 1) forman regiones aisladas, consistente con la menor calidad de reconstrucción y la dificultad de comprimir información volumétrica en $d_z = 16$. En **CelebA**, la proyección muestra una nube circular continua sin agrupación discreta, coherente con la naturaleza continua de los atributos faciales: el modelo aproxima globalmente el prior gaussiano pero no organiza el espacio en regiones semánticamente distinguibles.




Figura 3: Proyecciones t-SNE 2D de las medias latentes μ_ϕ en test con $d_z = 16$ (MNIST) y $d_z = 64$ (CelebA). Fila superior: VAE (izq.) vs. β -VAE (dcha.) en MNIST-2D. Fila central: VAE (izq.) vs. β -VAE (dcha.) en MNIST-3D. Fila inferior: VAE en CelebA (nube continua sin etiquetas de clase).

5.1.5. Interpolaciones en el espacio latente

La Figura 4 muestra interpolaciones lineales entre pares de muestras de test con $d_z = 64$. En **MNIST-2D** ($n_{\text{interp}} = 10$, sobre muestras reparametrizadas), la transición $7 \rightarrow 2$ es suave y semánticamente coherente, confirmando la continuidad local del espacio latente. En **MNIST-3D** ($n_{\text{interp}} = 15$, sobre las medias μ_ϕ), la transición es reconocible aunque más ruidosa: las celdas de borde presentan activaciones intermedias difusas propias de la representación binaria, pero la estructura global evoluciona de forma continua. En CelebA ($n_{\text{interp}}=10$), la interpolación sí permite apreciar dos identidades distintas en los extremos, pero la transición intermedia no es semánticamente coherente: en lugar de un morph gradual entre rostros, aparecen regiones borrosas y artefactos visuales que sugieren que el espacio latente no ha organizado los factores de identidad de forma disentangled. Esto es consistente con la proyección t-SNE, que muestra una nube continua sin agrupamiento semántico claro.




Figura 4: Interpolaciones lineales en el espacio latente con $d_z = 64$. De arriba a abajo: β -VAE MNIST-2D (transición $7 \rightarrow 2$, $n_{\text{interp}} = 10$); β -VAE MNIST-3D (corte central del volumen vóxel, $n_{\text{interp}} = 15$, interpolación sobre μ_ϕ); VAE CelebA (transición entre dos imágenes del mismo sujeto, $n_{\text{interp}} = 10$).

5.1.6. Comparativa VAE vs. β -VAE y limitaciones

El β -VAE con annealing cíclico supera al VAE estándar en los criterios cualitativos: clusters t-SNE ligeramente más compactos en MNIST-2D, interpolaciones más suaves inter-clase, y ausencia de *posterior collapse* en d_z reducido. Las pérdidas de reconstrucción convergen a valores similares para d_z suficientemente grande, confirmando que el annealing no penaliza la calidad de reconstrucción. No obstante, los resultados revelan los límites de la arquitectura convolucional diseñada para 32×32 : en CelebA la reconstrucción es insuficiente para recuperar rasgos faciales identificables y el espacio latente no organiza estructura semántica; en Food-101 la reconstrucción es directamente inservible. Estas limitaciones, junto con el coste computacional asociado a 224×224 en hardware común de usuario, motivaron el rediseño metodológico de la Parte 2 sobre BPS, donde la dimensión de entrada es controlable mediante K y la tarea se alinea con las capacidades del modelo generativo.

5.2. Parte 2. Ciclycal β -VAE + BPS en ModelNet

5.2.1. Configuración experimental

Los experimentos se ejecutaron con $\text{SEED} = 42$ en todas las configuraciones. El dispositivo de cómputo fueron varias GPUs ya que cada integrante del grupo disponía de un equipo diferente. La Tabla 6 recoge las versiones de las librerías principales.

Tabla 6: Entorno software de los experimentos.

Librería	Versión
PyTorch	2.11.0
scikit-learn	1.8.0
XGBoost	3.2.0
bps	git@26788bc
NumPy	2.4.4
SciPy	1.17.1
Matplotlib	3.10.8

5.2.2. Resultados comparativos

La Tabla 7 recoge la exactitud en el conjunto de test (*Overall Accuracy*, OA) del mejor modelo obtenido tras la búsqueda de hiperparámetros para cada combinación de subconjunto de ModelNet y resolución BPS K , junto con las líneas de referencia de k -NN y XGBoost aplicados sobre las medias latentes μ_ϕ .

Tabla 7: Exactitud en test (%) por dataset y resolución BPS. En negrita, la mejor configuración de cada dataset.

Dataset	K	VAE+Cls	kNN (μ)	XGBoost (μ)
ModelNet3	256	77.06	78.24	20.00
	512	95.60	94.80	95.20
	1024	96.40	96.00	95.60
ModelNet10	256	94.58	94.93	93.36
	512	94.76	94.58	92.66
	1024	95.45	95.63	94.23
ModelNet25	256	87.90	88.96	83.97
	512	90.31	90.31	86.58
	1024	88.96	88.96	85.61
ModelNet40	256	81.52	81.16	75.24
	512	81.81	81.08	77.27
	1024	82.54	82.05	76.70

Los resultados de la Tabla 7 revelan dos tendencias principales. En primer lugar, el sistema BPS + β -VAE es capaz de alcanzar exactitudes competitivas en todos los subconjuntos de ModelNet. En segundo lugar, la diferencia entre la cabeza neuronal y los métodos de aprendizaje automático clásico (k -NN y XGBoost) sobre el mismo espacio latente es pequeña (< 2 puntos porcentuales en la mayoría de configuraciones), lo que indica que no siempre es óptimo aplicar un modelo más complejo en ya que con modelos mucho más sencillos y rápidos de entrenar se han obtenido resultados muy similares.

5.2.3. Efecto de la resolución BPS

Tabla 8: Ganancia de exactitud (VAE+Cls, %) al incrementar K .

K	MNet3	MNet10	MNet25	MNet40
256	77.06	94.58	87.90	81.52
512	95.60	94.76	90.31	81.81
1024	96.40	95.45	88.96	82.54
$\Delta(256 \rightarrow 1024)$	+19.3	+0.9	+1.1	+1.0

La Tabla 8 muestra que el efecto de incrementar la resolución K es pronunciado únicamente en ModelNet3, donde el salto de $K = 256$ a $K = 512$ supone una ganancia de +18,5 puntos porcentuales (de 77.06 % a 95.60 %), y el paso a $K = 1024$ añade apenas +0,8 puntos adicionales. Esta saturación sugiere que, para tres clases de geometrías bien diferenciadas (*airplane*, *bathtub*, *table*), 512 puntos de base son suficientes para capturar la variabilidad geométrica discriminativa. En los datasets de mayor complejidad (ModelNet10, 25 y 40), la ganancia al duplicar K de 256 a 1024 es marginal ($\leq 1,1$ puntos), lo que sugiere que el límite de rendimiento viene impuesto principalmente por la capacidad del espacio latente de dimensión $d_z = 64$ para organizar 40 categorías geoméricamente distintas, y no por la resolución de la representación BPS.

Desde el punto de vista del coste computacional, la dimensión de entrada crece linealmente con K ($3K \in \{768, 1536, 3072\}$), lo que implica que el coste por época del modelo más grande es cuatro veces superior al más pequeño. Dado que la ganancia de exactitud en ModelNet10-40 es inferior a 1 punto porcentual por cada duplicación de K , la configuración $K = 512$ representa el mejor compromiso entre rendimiento y coste.

5.2.4. Comparativa aprendizaje profundo vs. aprendizaje automático clásico




Figura 5: Comparativa VAE+Cls vs. k -NN vs. XGBoost sobre medias latentes. Izq: ModelNet40-1024 (comportamiento típico). Drch: ModelNet25-256 (kNN y XGBoost superan a la red neuronal).

La Figura 5 ilustra los dos casos más representativos. En **ModelNet40-1024** la diferencia es mínima (VAE+Cls 82.54 %, k -NN 82.05 %, XGBoost 76.70 %), con ventaja de apenas +0,5 puntos del VAE frente al k -NN. En **ModelNet25-256** el k -NN supera incluso a la cabeza neuronal por +1,1 puntos (88.96 % vs. 87.90 %). La lección global es que el aprendizaje profundo no garantiza superioridad sobre los métodos clásicos cuando: (a) la representación de entrada ya está bien estructurada (BPS), (b) el hardware impide explorar arquitecturas más grandes o más épocas, y (c) la optimización conjunta de múltiples objetivos (rec., KL, Chamfer, CE) genera superficies de pérdida complejas que dificultan la convergencia.

5.2.5. Estructura del espacio latente




Figura 6: Proyección t-SNE para ModelNet3, ModelNet10 y ModelNet40 con $K = 1024$.

La Figura 6 muestra las proyecciones t-SNE de las medias latentes μ_ϕ con $K = 1024$. En **ModelNet3** los tres clusters (*airplane*, *bathtub*, *table*) aparecen claramente separados con márgenes amplios tanto en train como en test, consistente con la exactitud del 96.40 %. En **ModelNet10** los diez clusters son distinguibles con mínimo solapamiento; las clases visualmente confundibles (p.ej. *desk*/*mantel*) muestran mayor proximidad. En **ModelNet40**, aunque emergen regiones de densidad por categoría, el solapamiento es considerable, especialmente en test, donde grupos geoméricamente similares (*bench*/*chair*, *curtain*/*plant*, *sink*/*bowl*) forman regiones adyacentes difíciles de separar.

5.2.6. Calidad de reconstrucción e interpolación en el espacio latente




Figura 7: Reconstrucción de nubes de puntos en ModelNet10-1024: nube original (GT, verde) frente a reconstrucción del decoder (azul). Las columnas muestran distintas clases del conjunto de test.




Figura 8: Izquierda: interpolación intra-clase en el espacio latente (misma categoría). Derecha: interpolación inter-clase (transición entre dos categorías distintas), evidenciando la continuidad del espacio latente aprendido.

La Figura 7 compara nubes originales (verde) y reconstruidas (azul) para las diez clases de ModelNet10-1024. La distancia de Chamfer (CD) varía notablemente entre clases: objetos compactos y regulares como *keyboard* (CD=1.73) o *glass_box* (CD=2.77) se reconstruyen con alta fidelidad, mientras que geometrías dispersas o irregulares como *desk* (CD=61.65) o *laptop* (CD=55.35) presentan errores elevados. Es importante notar que esta variabilidad no se corresponde directamente con la exactitud de clasificación: el β -VAE puede aprender representaciones discriminativas incluso con reconstrucción imperfecta, dado que la cabeza clasificadora opera sobre μ_ϕ .

La Figura 8 evidencia un espacio latente continuo y semánticamente coherente. En la interpolación intra-clase (*lamp* $\rightarrow$ *lamp*), las formas intermedias mantienen la identidad semántica (transición de cilíndrico a esférico sin perder la estructura de lámpara). En la inter-clase (*flower_pot* $\rightarrow$ *glass_box*), la maceta esférica se va alargando y aplanando hasta adoptar la estructura de la caja, pasando por formas intermedias. El espacio latente no solo clasifica: organiza las formas 3D de manera interpolable y generativa, propiedad ausente en los clasificadores deterministas del estado del arte.

5.2.7. Comparación con el estado del arte en ModelNet10 y ModelNet40

Las Tablas 9 y 10 sitúan los resultados del presente trabajo en el contexto de los métodos de referencia recogidos en los *benchmarks* públicos de OpenCodePapers [18, 19]. Se han seleccionado representantes de las principales familias metodológicas ordenados cronológicamente para ilustrar la evolución del campo.

Tabla 9: Comparativa con el estado del arte en ModelNet40 (OA, %)

Método	Representación	OA (%)	Año
3D ShapeNets [5]	Vóxeles (CDBN)	77.3	2015
PointNet [8]	Nube de puntos (MLP)	89.2	2016
PointNet++ [9]	Nube de puntos (jer.)	90.7	2017
DGCNN [10]	Grafo dinámico	92.9	2018
PCT [11]	Transformer	93.2	2020
PointMLP [12]	MLP residual	94.5	2022
PointGST [13]	Fine-tuning espectral	95.3	2024
Nuestro: BPS + β-VAE ($K=1024$)	BPS (VAE + Cls)	82.54	2026

Tabla 10: Comparativa con el estado del arte en ModelNet10 (OA, %)

Método	Representación	OA (%)	Año
ECC [14]	Grafo (filtros dinámicos)	90.0	2017
G3DNet [15]	Extractor profundo gen.	93.1	2018
ORION [16]	Vóxeles orientados	93.8	2016
PolyNet [17]	Repr. polinómica	94.93	2021
Nuestro: BPS + β-VAE ($K=1024$)	BPS (VAE + Cls)	95.45	2026

En **ModelNet40**, el sistema alcanza el 82.54 %, cifra significativamente por debajo de los métodos supervisados del estado del arte: $-6,7$ puntos frente a PointNet (89.2 %) y $-12,8$ frente a PointGST (95.3 %). Esta brecha refleja dos factores: (i) todos los métodos de referencia optimizan un único objetivo discriminativo, mientras que aquí la capacidad de la red se reparte entre reconstrucción, KL, Chamfer y clasificación; (ii) las arquitecturas basadas en grafos dinámicos (DGCNN, PointMLP) y transformers (PCT, PointGST) capturan relaciones locales entre puntos vecinos que BPS no modela explícitamente, factor determinante para discriminar las 40 categorías de ModelNet40 donde los detalles de forma local son informativos.

En **ModelNet10**, en cambio, el sistema obtiene el 95.45 %, superando a todos los métodos del *benchmark* de OpenCodePapers incluido PolyNet (94.93 %), hasta la fecha el mejor registrado. Es destacable que el resultado se obtenga con un objetivo compartido entre generación y clasificación, lo que indica que BPS con $K = 1024$ captura suficiente información discriminativa para las 10 categorías cuando las diferencias inter-clase son pronunciadas. En conjunto, el sistema se posiciona como una solución eficiente para entornos de recursos limitados: con una arquitectura MLP de capacidad moderada y entrenamiento extremo a extremo se alcanzan resultados competitivos en ModelNet10 y razonables en ModelNet40, conservando además la capacidad generativa (reconstrucción e interpolación), funcionalidad ausente en todos los métodos del ranking.

6. Conclusiones

El trabajo ha explorado la capacidad de los Autocodificadores Variacionales con annealing cíclico del hiperparámetro β para aprender representaciones estructuradas en dominios visuales de complejidad creciente. A lo largo de las dos partes del proyecto se han obtenido resultados que permiten extraer conclusiones tanto sobre la validez del enfoque como sobre sus limitaciones inherentes.

En la Parte 1, el β -VAE con *cyclical annealing* ha demostrado ser superior al VAE estándar en todos los criterios cualitativos evaluados: produce clusters más compactos en las proyecciones t-SNE de MNIST-2D y MNIST-3D, evita el *posterior collapse* que aparece con β fijo en dimensiones

latentes reducidas, y genera interpolaciones más suaves en la región inter-clase. La dinámica cíclica de β permite que el modelo alterne entre fases de reconstrucción libre y fases de regularización, aprendiendo ambos objetivos de forma complementaria en lugar de sacrificar uno por el otro. Sin embargo, los experimentos sobre CelebA y Food-101 han puesto de manifiesto los límites de la arquitectura convolucional empleada: diseñada para resoluciones de 32×32 , no escala eficientemente a entradas de mayor complejidad, produciendo reconstrucciones borrosas en CelebA e inservibles en Food-101, donde además fueron necesarias modificaciones de estabilización numérica que degradaron adicionalmente la calidad del aprendizaje.

En la Parte 2, la combinación de BPS y β -VAE cíclico ha producido el resultado más destacable del proyecto: una exactitud del 95.45 % en ModelNet10 que supera a todos los métodos recogidos en el benchmark público, incluido PolyNet (94.93 %), obtenida con una arquitectura MLP de capacidad moderada y un único proceso de entrenamiento extremo a extremo que optimiza simultáneamente reconstrucción, regularización KL, geometría 3D y clasificación. En ModelNet40, en cambio, el sistema alcanza el 82.54 %, quedando por debajo de los métodos supervisados especializados debido a dos factores estructurales: la optimización de múltiples objetivos reduce la capacidad efectiva dedicada a la discriminación, y la codificación BPS global no captura las relaciones locales entre puntos vecinos que resultan determinantes para distinguir 40 categorías con diferencias geométricas sutiles. El análisis del efecto de la resolución BPS ha revelado además que el cuello de botella en ModelNet10-40 no reside en la representación sino en la dimensión del espacio latente ($d_z = 64$), y que la configuración $K = 512$ ofrece el mejor compromiso entre rendimiento y coste computacional.

Una lección a ambas partes es que el aprendizaje profundo no garantiza superioridad sobre los métodos clásicos cuando la representación de entrada ya está bien estructurada. La pequeña diferencia entre VAE+Cls y k -NN sobre el mismo espacio latente (inferior a 2 puntos porcentuales en la mayoría de configuraciones) indica que gran parte de la información discriminativa reside en la propia codificación BPS, y que la complejidad adicional de la red solo se justifica cuando se busca también la capacidad generativa: la reconstrucción e interpolación de formas 3D, funcionalidad ausente en la totalidad de los clasificadores del estado del arte.

Como líneas de trabajo futuro, tres direcciones concretas emergen de las limitaciones identificadas. En primer lugar, sustituir la codificación BPS global por una representación jerárquica que capture relaciones locales entre puntos vecinos, como la propuesta por PointNet++, permitiría reducir la brecha con el estado del arte en ModelNet40 sin abandonar el marco generativo. En segundo lugar, aumentar la dimensión del espacio latente más allá de $d_z = 64$ o introducir un prior estructurado por clases, como un prior de mezcla de gaussianas, podría mejorar la separabilidad de las 40 categorías sin sacrificar la capacidad de reconstrucción. Finalmente, en la Parte 1, el diseño de arquitecturas convolucionales adaptadas a resoluciones de 224×224 o la adopción de un encoder preentrenado como Vision Transformer permitiría explorar la capacidad generativa del β -VAE sobre datasets de alta resolución como Food-101, donde la arquitectura actual resultó insuficiente.

Referencias

- [1] J. de la Torre, “Autocodificadores Variacionales (VAE): Fundamentos Teóricos y Aplicaciones,” *Survey*, Universitat Oberta de Catalunya, 2023.
- [2] S. Prokudin, C. Lassner y J. Romero, “Efficient Learning on Point Clouds with Basis Point Sets,” *arXiv preprint arXiv:1908.09186*, 2019. [arXiv:1908.09186](#)
- [3] I. Higgins, L. Matthey, A. Pal, C. Burgess, X. Glorot, M. Botvinick, S. Mohamed y A. Lerchner, “ β -VAE: Learning Basic Visual Concepts with a Constrained Variational Framework,” *International Conference on Learning Representations (ICLR)*, 2017. [ICLR:Sy2fzU9gl](#)
- [4] D. P. Kingma y M. Welling, “Auto-Encoding Variational Bayes,” *arXiv preprint arXiv:1312.6114*, 2013. [arXiv:1312.6114](#)
- [5] Z. Wu, S. Song, A. Khosla, F. Yu, L. Zhang, X. Tang y J. Xiao, “3D ShapeNets: A deep representation for volumetric shapes,” *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 1912–1920, 2015. [DOI:10.1109/CVPR.2015.7298801](#)
- [6] H. Fu, C. Li, X. Liu, J. Gao, A. Celikyilmaz y L. Carin, “Cyclical Annealing Schedule: A Simple Approach to Mitigating KL Vanishing,” *arXiv preprint arXiv:1903.10145*, 2019. [arXiv:1903.10145](#)
- [7] P. Achlioptas, O. Diamanti, I. Mitliagkas y L. Guibas, “Learning Representations and Generative Models for 3D Point Clouds,” *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pp. 40–49, 2018. [DOI: 10.48550/arXiv.1707.02392](#)
- [8] C. R. Qi, H. Su, K. Mo y L. J. Guibas, “PointNet: Deep Learning on Point Sets for 3D Classification and Segmentation,” *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 652–660, 2017. [arXiv:1612.00593](#)
- [9] C. R. Qi, L. Yi, H. Su y L. J. Guibas, “PointNet++: Deep Hierarchical Feature Learning on Point Sets in a Metric Space,” *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017. [arXiv:1706.02413](#)
- [10] Y. Wang, Y. Sun, Z. Liu, S. E. Sarma, M. M. Bronstein y J. M. Solomon, “Dynamic Graph CNN for Learning on Point Clouds,” *ACM Transactions on Graphics*, vol. 38, no. 5, art. 146, 2019. [arXiv:1801.07829](#)
- [11] M.-H. Guo, J.-X. Cai, Z.-N. Liu, T.-J. Mu, R. R. Martin y S.-M. Hu, “PCT: Point Cloud Transformer,” *Computational Visual Media*, vol. 7, no. 2, pp. 187–199, 2021. [arXiv:2012.09688](#)
- [12] X. Ma, C. Qin, H. You, H. Ran y Y. Fu, “Rethinking Network Design and Local Geometry in Point Cloud: A Simple Residual MLP Framework,” *ICLR*, 2022. [arXiv:2202.07123](#)
- [13] Z. Feng, Z. Li, C. Fang, X. Lin, R. Zhang y H. Chen, “Parameter-Efficient Fine-Tuning in Spectral Domain for Point Cloud Learning,” *arXiv preprint*, 2024. [arXiv:2410.08114](#)
- [14] M. Simonovsky y N. Komodakis, “Dynamic Edge-Conditioned Filters in Convolutional Neural Networks on Graphs,” *Proc. IEEE/CVF CVPR*, pp. 3693–3702, 2017. [arXiv:1704.02901](#)
- [15] P. Wang, Y. Gan, P. Shui, F. Yu, Y. Zhang, S. Chen y Z. Sun, “General-Purpose Deep Point Cloud Feature Extractor,” *IEEE Winter Conf. on Applications of Computer Vision (WACV)*, 2018.
- [16] N. Sedaghat, M. Zolfaghari y T. Brox, “Orientation-boosted Voxel Nets for 3D Object Recognition,” *arXiv preprint*, 2016. [arXiv:1604.03351](#)

- [17] M. Yavartanoo, J. Hung, S. Choi y K. M. Lee, “PolyNet: Polynomial Neural Network for 3D Shape Recognition with PolyShape Representation,” *arXiv preprint*, 2021. [arXiv:2110.07882](https://arxiv.org/abs/2110.07882)
- [18] OpenCodePapers, “3D Point Cloud Classification on ModelNet40,” [https : / / opencodepapers-b7572d . gitlab . io / benchmarks / 3d-point-cloud-classification-on-modelnet40.html](https://opencodepapers-b7572d.gitlab.io/benchmarks/3d-point-cloud-classification-on-modelnet40.html), consultado en mayo de 2026.
- [19] OpenCodePapers, “3D Object Classification on ModelNet10,” [https : / / opencodepapers-b7572d . gitlab . io / benchmarks / 3d-object-classification-on-modelnet10.html](https://opencodepapers-b7572d.gitlab.io/benchmarks/3d-object-classification-on-modelnet10.html), consultado en mayo de 2026.

A. Contribución individual

Tabla 11: Contribución de cada miembro del grupo.

Miembro	Contribución principal
Irene y Adrián	Sección 2 y Sección 1
Marcos y Luna	Sección 3 y Sección 4
Todos	Sección 5

B. Enlace al repositorio

El código fuente del trabajo está disponible en: [Repositorio del proyecto](#)

C. Enlace Kaggle

El proyecto está disponible en: [Link Kaggle](#)