

Redes Neuronales y Aprendizaje Profundo

β -VAE con Cyclical Annealing

Aprendizaje de representaciones estructuradas en datos 2D/3D

Marcos Francés Requena · Luna Camacho Boluda · Irene Fátima Robles Cano · Ángel Adrián Bustios Cancino

Grado en Ingeniería en IA · Universidad de Alicante · 2025/2026

Índice de Contenidos

01

Introducción

Motivación y objetivos del proyecto

02

Trabajo Relacionado

VAE, β -VAE, Cyclical Annealing, BPS, ModelNet

03

Descripción del Problema y los Datos

Parte 1 (2D/3D) · Parte 2 (ModelNet)

04

Metodología

Preprocesamiento, modelos, protocolo de evaluación

05

Experimentos y Resultados

Entrenamiento, reconstrucción, espacio latente, clasificación

06

Conclusiones

Hallazgos y líneas futuras

01 · Introducción

Problema central

Aprendizaje de representaciones estructuradas en datos visuales de alta dimensionalidad mediante modelos generativos probabilísticos (β -VAE).

Reto técnico

Posterior collapse y tensión entre fidelidad de reconstrucción y regularización KL → solución: Cyclical Annealing.

Parte 1

VAE y β -VAE cíclico sobre MNIST-2D, CelebA, Food-101 y MNIST-3D.

Parte 2

Clasificación 3D en ModelNet con codificación BPS + β -VAE cíclico. Escalabilidad de 3 a 40 clases.

02 • Trabajo Relacionado

VAE [Kingma & Welling]

Prior gaussiano, ELBO, truco de reparametrización. Representación continua generativa.

β -VAE [Higgins et al.]

$\beta \geq 1$ fuerza factorización latente. Compromiso reconstrucción–disentanglement.

Cyclical Annealing [Fu et al.]

β cicla 0→1 repetidamente. Evita KL vanishing; estructura latente progresiva.

BPS [Prokudin et al.]

K puntos base → vector distancias fijas. $O(n \log n + k \log n)$. Apto para MLP/SVM.

ModelNet [Wu et al.]

Benchmark 3D estándar. ModelNet10 y ModelNet40 con particiones fijas.

Achlioptas et al.

Autoencoder profundo sobre nubes de puntos. Espacio latente útil para clasificación e interpolación.

03 · Parte 1 — β -VAE en datos 2D/3D

TAREA

- **Aprendizaje No Supervisado**
- **D -> Distribución paramétrica -> z**
 - ❑ **Encoder:** $q\phi(z|x) = N(\mu\phi, \text{diag } \sigma^2\phi)$
 - ❑ **Decoder:** $p\phi(x|z)$
- **Pérdida β -VAE:** $L = L_{\text{rec}} + \beta \cdot \text{DKL}$
- **β cíclico:** C=4 ciclos, 100 épocas, rampa lineal 0→1

ENTRENAMIENTO

- **dz** $\in \{2, 4, 8, 16, 32, 48, 64, 128\}$
- **Optimizador Adam** ($\alpha=1e-3$)
- **Early stopping** p=20 épocas

Datasets — Parte 1

Dataset	Modalidad	Instancias
MNIST-2D	1×32×32	60k train
MNIST-3D	1×32 ³ vóxel	5k train
CelebA	1×32×32	162k train
Food-101	3×224×224	3k (4 cls.)

03 · Parte 2 — Cyclical β -VAE + BPS en ModelNet

TAREA

- Clasificación nubes puntos 3D
- Representación BPS
- β -VAE cíclico
- β cíclico: C=1, 25 épocas, función cosenoidal

Función de pérdida total (Parte 2)

$$L = \text{MSE_BPS} + \beta(t) \cdot D_{\text{KL}} + \lambda_{\text{Ch}} \cdot d_{\text{Chamfer}} + \lambda_{\text{CE}} \cdot L_{\text{CE}}$$

ModelNet3

ModelNet10

ModelNet25

ModelNet40

Malla OFF

Muestreo 1000 pts

Normalización
esfera unitaria

Codificación BPS
(K=256/512/1024)

Estandarización
(μ, σ de train)

β -VAE +
Clasificador

04 · Metodología — Parte 1

Preprocesamiento por dataset

Dataset	Transformaciones	Res.
MNIST-2D	Resize 32, Norm(0.5,0.5)	32×32 ×1
MNIST-3D	Voxel min-max 32^3 , (v-0.5)/0.5	$32^3 \times 1$
CelebA	CenterCrop(178)→32, Grayscale, Norm	32×32 ×1
Food-101	Resize 224, Norm((0.5)×3)	224×224 ×3

VAE baseline vs β -VAE + Cyclical Annealing

VAE ($\beta=1$ fijo): línea base. Misma arquitectura conv. | **β -VAE cíclico:** C=4, E=100, β 0→1 lineal. Evita posterior collapse.

Arquitectura encoder (2D)

Input $x \in \mathbb{R}^{\text{C} \times \text{H} \times \text{W}}$

Conv2d 4×4 s2 p1 + BN + LReLU

Conv2d 4×4 s2 p1 + BN + LReLU

Conv2d 4×4 s2 p1 + BN + LReLU

Flatten → 2048

Linear → $\mu\phi \in \mathbb{R}^{\text{dz}}$

Protocolo de evaluación

MSE test · t-SNE latente · Interpolaciones $z(\alpha)=(1-\alpha)z_1+\alpha z_2$

04 · Metodología — Parte 2

Arquitecturas del encoder/decoder

V1 (base)

3K $\rightarrow$ 1024 $\rightarrow$ 512 $\rightarrow$ 256 $\rightarrow$ dz

V2 (deeper)

3K $\rightarrow$ 1024 $\rightarrow$ 768 $\rightarrow$ 512 $\rightarrow$ 256 $\rightarrow$ dz

V3 (wider)

3K $\rightarrow$ 1536 $\rightarrow$ 1024 $\rightarrow$ 512 $\rightarrow$ dz

Grid Search hiperparámetros

Tasa aprendizaje η	{1e-4, 5e-5}
Batch size	{32, 64}
Regulariz. L2 λ WD	{1e-5, 1e-6}
Peso Chamfer λ Ch	{0.5, 1.0}
Peso clasif. λ CE	{1.0, 2.0}
Inicialización	Kaiming / Xavier uniforme / normal

Comparativa con métodos clásicos (sobre mismo espacio latente)

VAE

Sobre BPS directamente. Baseline discriminativo.

k-NN (k=5)

Sobre medias latentes $\mu\phi$ del encoder entrenado.

XGBoost (100 árboles)

Profundidad 5, $\eta=0.1$, sobre medias latentes $\mu\phi$.

05 · Dinámica del entrenamiento — Cyclical Annealing

Reinicio cíclico de β


Al inicio de cada ciclo $\beta \rightarrow 0$: la presión KL desaparece y la reconstrucción mejora bruscamente.

Evita posterior collapse

La alternancia permite aprender reconstrucción Y organización latente de forma complementaria.


Convergencia rápida

MSE cae de ~ 8300 a < 300 en las primeras 10 épocas. Early stopping en torno a la época 73.




05 · Calidad de reconstrucción visual

Epoch 1 - Reconstrucción paso a paso




Epoch 10 - Reconstrucción paso a paso (Corte 2D)



05 · Calidad de reconstrucción visual

Epoch 16



Epoch 54 - Reconstrucción paso a paso



05 · Calidad de reconstrucción visual

Perfecta ✓

MNIST-2D — Época 1

Dígitos indistinguibles de los originales desde la 1.^a época.

Buena

MNIST-3D — Época 10

Estructura 3D reconocible. Pixelado en bordes (representación binaria).

Borrosa

CelebA — Época 16



Estructura facial preservada. Sin detalles finos ($32 \times 32 + dz=64$ insuficiente).

Deficiente ✗

Food-101 — Época 54



Solo color global. Arquitectura 32×32 no escala a 224×224 .

05 · Estructura del espacio latente — t-SNE




Cyclical Annealing → clusters más compactos en 2D sin usar etiquetas durante el entrenamiento

05 · Estructura del espacio latente — t-SNE



Cyclical Annealing → clusters más compactos en 2D sin usar etiquetas durante el entrenamiento

05 · Estructura del espacio latente — t-SNE



Cyclical Annealing → clusters más compactos en 2D sin usar etiquetas durante el entrenamiento

05 · Estructura del espacio latente — t-SNE

MNIST-2D (dz=16)

VAE: 10 clusters bien separados β -VAE: Clusters más compactos, menor solapamiento entre 3/8 y 4/9.

MNIST-3D (dz=16)

VAE: Clusters solapados, solo '1' aislado β -VAE: Similar dificultad; la dimensión volumétrica penaliza la separación.

CelebA (dz=64)

VAE: Nube circular continua, sin clusters.



Cyclical Annealing → clusters más compactos en 2D sin usar etiquetas durante el entrenamiento

05 · Interpolaciones en el espacio latente



05 · Interpolaciones en el espacio latente

MNIST-2D (β -VAE)

$$z(\alpha) = (1-\alpha)z_1 + \alpha \cdot z_2, \text{ ninterp}=10$$

Transición 7→2 suave y semánticamente coherente. Confirma espacio continuo.

MNIST-3D (β -VAE)

Interpolación directa sobre $\mu\phi$, ninterp=15


Transición volumétrica reconocible. Bordes difusos (representación binaria).

CelebA (VAE)


Interpolación sobre muestras reparametrizadas, ninterp=10

Sin cambio de identidad a lo largo del trayecto. El decoder colapsa a una representación dominante.

05 · Resultados Parte 2 — Espacios latentes (MN3-1024)




05 · Resultados Parte 2 — Espacios latentes (MN3-1024)



Confusion Matrix — Test set

	airplane	bathtub	table
True label			
airplane	100	0	0
bathtub	1	44	5
table	0	3	97
	airplane	bathtub	table
	Predicted label		


05 · Resultados Parte 2 — Espacios latentes (MN10-1024)




05 · Resultados Parte 2 — Espacios latentes (MN10-1024)

3D Latent Space Visualization


- desk
- door
- dresser
- flower_pot
- glass_box
- keyboard
- lamp
- laptop
- mantel
- monitor



Confusion Matrix — Test set



05 · Resultados Parte 2 — Espacios latentes (MN40-1024)



05 · Resultados Parte 2 — Espacios latentes (MN40-1024)

3D Latent Space Visualization

- airplane
- bathtub
- bed
- bench
- bookshelf
- bottle
- bowl
- car
- chair
- cone
- cup
- curtain
- desk
- door
- dresser
- flower_pot
- glass_box
- guitar
- keyboard
- lamp
- laptop
- mantel
- monitor
- night_stand
- person
- piano
- plant
- radio
- range_hood
- sink
- sofa
- stairs
- stool
- table
- tent
- toilet
- tv_stand
- vase
- wardrobe
- xbox



05 · Reconstrucción 3D e interpolación en el espacio latente

$\alpha=0.00$



$\alpha=0.25$



Intra-class: lamp $\rightarrow$ lamp

$\alpha=0.50$




$\alpha=0.75$



$\alpha=1.00$



$\alpha=0.00$



$\alpha=0.25$



Inter-class: flower_pot $\rightarrow$ glass_box


$\alpha=0.50$




$\alpha=0.75$



$\alpha=1.00$



05 · Efecto de BPS



+19.3 pts MNet3

K=256→512: salto masivo para 3 clases.
Geometrías simples muy sensibles a la resolución.



< 1.1 pts MNet10-40

Saturación en datasets complejos. El cuello de botella es dz=64, no la resolución BPS.

K=512 óptimo

Mejor compromiso rendimiento/coste. Coste ×4 de K=256 a K=1024 con ganancia marginal.

05 · Aprendizaje profundo vs. métodos clásicos



- La diferencia VAE+Cls vs k-NN es <2 pts en la mayoría de configuraciones.
- El DL no garantiza superioridad sobre métodos clásicos cuando la representación BPS ya es discriminativa.
- La ventaja del β -VAE reside en su capacidad GENERATIVA (reconstrucción e interpolación 3D).
- Entrenamiento multi-objetivo (4 pérdidas) dificulta la convergencia comparado con clasificadores puros.

05 · Comparación con el estado del arte

ModelNet40 (OA %)		ModelNet10 (OA %)	
3D ShapeNets	77.3 % 2015	ECC	90.0 % 2017
PointNet	89.2 % 2016	G3DNet	93.1 % 2018
PointNet++	90.7 % 2017	ORION	93.8 % 2016
DGCNN	92.9 % 2018	PolyNet	94.93 % 2021
PCT	93.2 % 2020	Nuestro (K=1024)	95.45 % 2026
PointMLP	94.5 % 2022		
PointGST	95.3 % 2024		
Nuestro (K=1024)	82.54 % 2026		

 **ModelNet10: superamos a PolyNet (SOTA anterior)**

ModelNet40: -12.8 pts vs PointGST (objetivo multi-tarea vs clasificación pura)

06 • Conclusiones

- ✓ β -VAE cíclico supera al VAE estándar: clusters más compactos, sin posterior collapse, interpolaciones más suaves.
- ✓ ModelNet10: 95.45 % $\rightarrow$ supera a PolyNet (SOTA) con arquitectura MLP y entrenamiento multi-objetivo.
- △ ModelNet40: 82.54 %, -12.8 pts vs PointGST. Causa: múltiples objetivos y ausencia de vecindad local en BPS.
- △ CelebA y Food-101: límites de la arquitectura 32×32 para entradas de alta resolución.
- $\rightarrow$ DL no garantiza superioridad sobre k-NN/XGBoost cuando la representación ya es discriminativa (<2 pts de diferencia).
- $\rightarrow$ El β -VAE añade valor generativo (reconstrucción e interpolación 3D) ausente en clasificadores del estado del arte.

¡Gracias!

Marcos Francés Requena · mfr73@alu.ua.es

Luna Camacho Boluda · lcb52@alu.ua.es

Irene Fátima Robles Cano · ifrc1@alu.ua.es

Ángel Adrián Bustios Cancino · aabc2@alu.ua.es